METHODS · 生成式檢索 / LLM-based Retrieval

STAIR：讓大型語言模型學會用「目錄」記憶並檢索長文件

STructure Aware Information Retriever — 以 Table of Contents 取代長度切塊的生成式檢索器

Vineet Kumar · Meghanadh Pulivarthi · Vishwajeet Kumar · Jaydeep Sen · Riyaz Ahmad Bhat · Sachindra Joshi

IBM

arXiv:2609.03874v1 [cs.AI] · 2026 年 9 月 3 日

研究背景

長度切塊會把文件天生的語意結構一起丟掉

— RAG （檢索增強生成）要精準檢索才能壓低幻覺； LLM 雖能處理更長上下文，仍受「 lost in the middle 」問題所苦。

— 主流檢索器把長文件切成固定長度的區塊（ length-based chunk ），卻丟棄了目錄（ ToC ）這類全域語意結構。

— 長度切塊之間缺乏語意邊界，彼此在檢索時互相競爭，導致檢索品質打折扣。

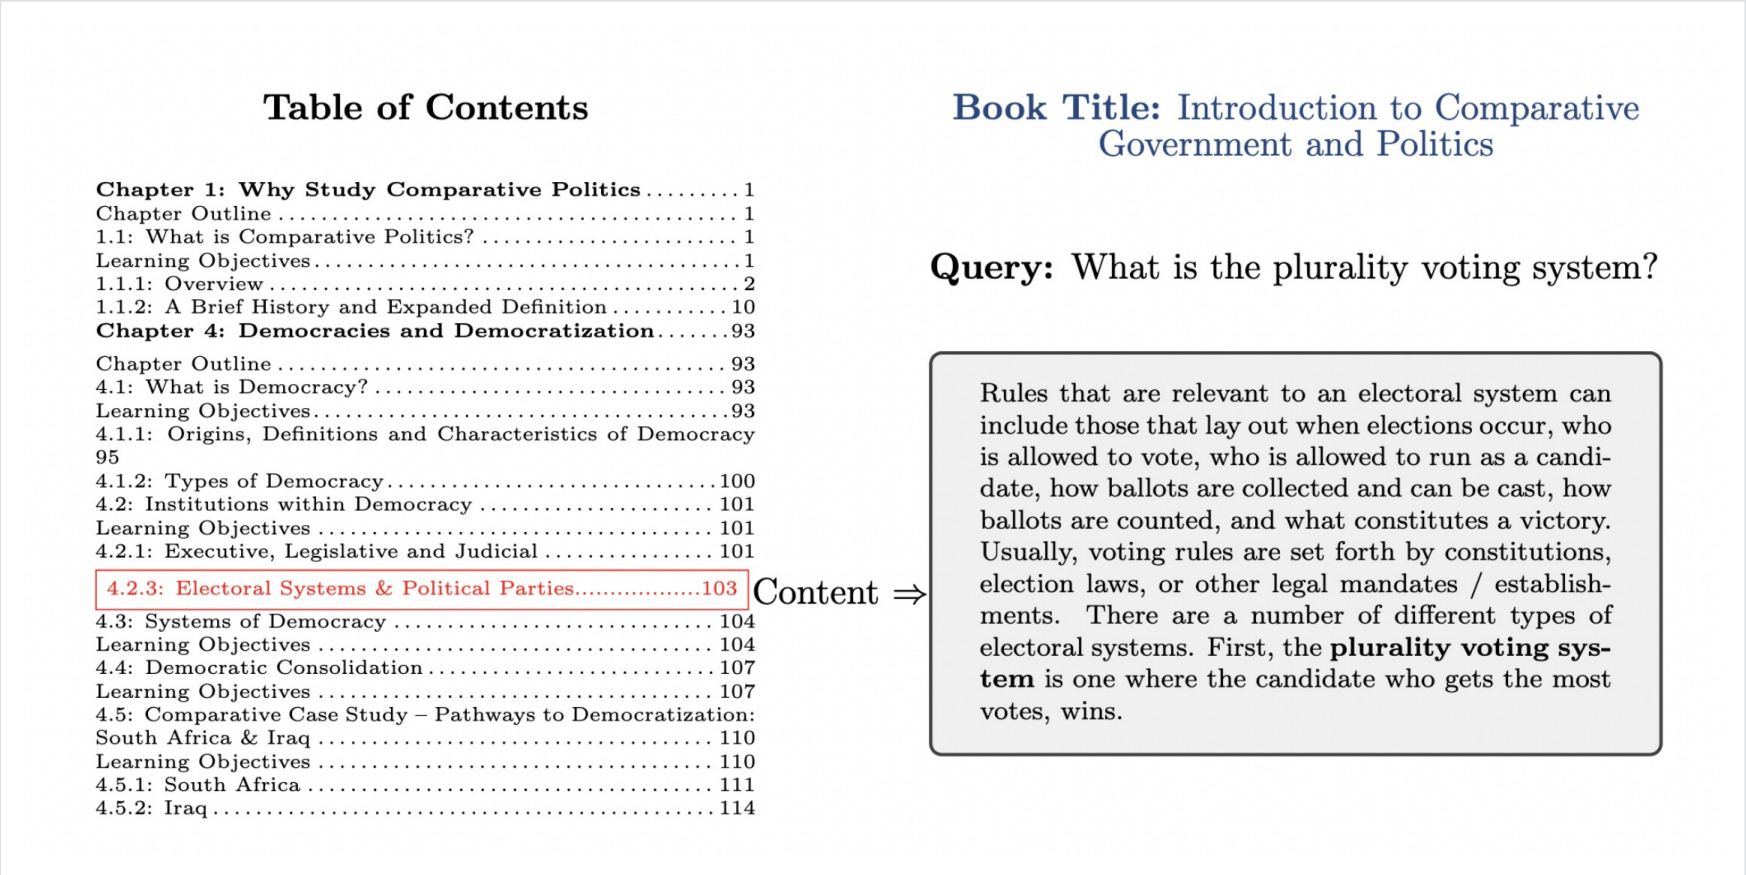
— 反觀 Wikipedia 條目、教科書、企業說明文件、 SEC 10-K 報告，本來就自帶清楚的目錄結構——這是一個被浪費的訊號。

STAIR 的出發點：把「目錄」還給檢索器，而不是切成無結構的長度區塊

Source: Introduction, arXiv:2609.03874v1, §1

動機

人類靠目錄定位答案，甚至不必通讀整本書

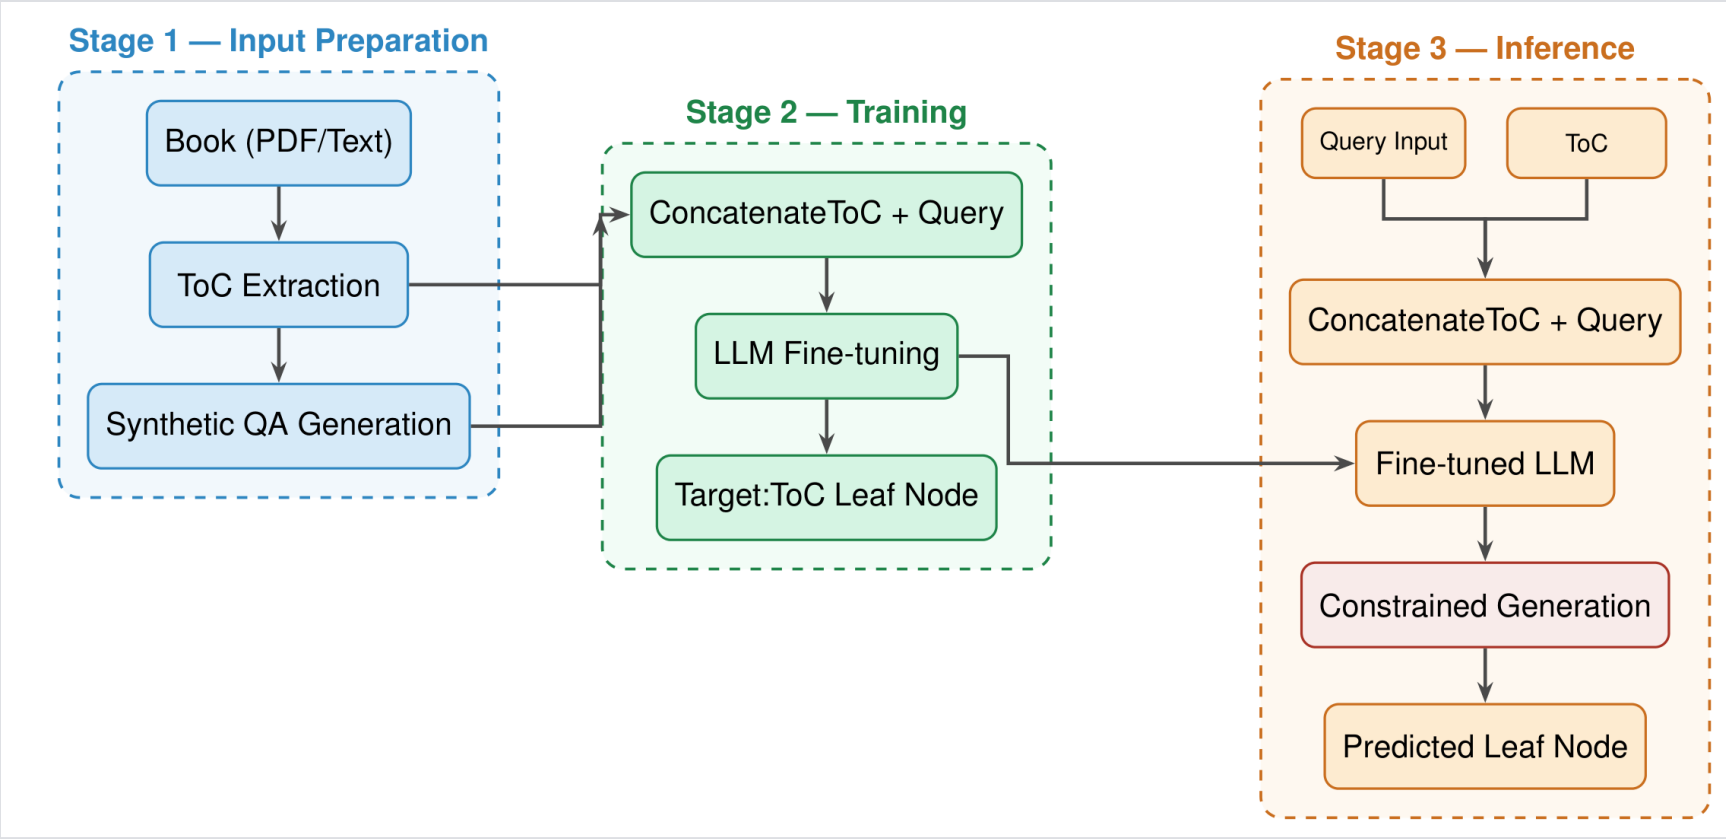


查詢「What is the plurality voting system?」時，讀者沿目錄找到「4.2.3 選舉制度與政黨」小節即可命中答案——ToC 條目與內容之間有清楚的語意邊界，這正是 STAIR 想教會 LLM 的能力。

Source: Figure 1, arXiv:2609.03874v1, p.2 — Introduction to Comparative Government and Politics

方法總覽

STAIR 用三階段流程把目錄結構直接教給 LLM



Stage 1 ・輸入準備

從書本抽取 ToC，並用 LLM 生成合成 QA 訓練資料

Stage 2 ・訓練

把「ToC + 查詢」拼接為輸入，微調 LLM 生成正確葉節點

Stage 3 ・推論

限制式生成（constrained generation）只允許輸出合法 ToC 葉節點

Source: Figure 2, arXiv:2609.03874v1, p.5

關鍵設計

把「目錄＋查詢」拼成一則提示，微調生成正確葉節點

訓練樣本（原文照錄）

```
### Book: Teaching in a Digital Age
Pick the best section from the table of contents below
which can answer the user query below. Only generate
the section name, do not generate any explanation!
### Table of Contents
1 Chapter 1: Fundamental Change in Education
  ...
leaf 12.7 Step five: master the technology
leaf 12.8 Step six: set appropriate learning goals
leaf 12.9 Step seven: design course structure and learning
  ...
leaf 13.7 Building the future
### Query: What is the suggested time allocation
for students studying a course or program?
### Section: leaf

Completion → 12.9 Step seven: design course structure and learning
```

— 語料知識內化：把整本書的內容對應到各章節標題，記入模型參數。

— 學習目錄推理：從完整的 ToC 全域結構中，挑出唯一能回答查詢的葉節點。

— 與 DSI 的差異只有一個： STAIR 的輸入裡多了完整 ToC ， DSI 必須自己從訓練資料裡「悟出」書的結構。

— 推論限制式生成只允許輸出合法葉節點，幾乎杜絕「生成不存在章節」的幻覺。

Source: Table 2 (sample training example) & §4.2, arXiv:2609.03874v1, p.5

新基準

SearchTome： 6 大領域、 18 本書、 19 萬則帶目錄標註的問題

領域	書籍數	總頁數	ToC 葉節點數	Train / Dev / Test 問題數
Education 教育	3	2,258	676	9,346 / 3,548 / 15,326
Finance 財務	3	1,967	285	9,834 / 3,963 / 16,415
Law 法律	3	2,248	605	16,824 / 6,578 / 27,472
Medicine 醫學	3	2,585	313	10,560 / 4,178 / 17,346
Natural Sciences 自然科學	3	1,941	516	9,364 / 3,705 / 15,719
Social Sciences 社會科學	3	1,476	485	6,530 / 2,530 / 10,971

18
本開放教科書，來源真實出版品

2,880
個 ToC 葉節點作為檢索目標

190,209
則 train/dev/test 問題， LLM 生成後人工留存

6
大領域：教育 / 財務 / 法律 / 醫學 / 自然科學 / 社會科學

Source: Table 1, arXiv:2609.03874v1, p.4 — 各領域數字為論文逐書統計加總（ Python 計算，非人工加總）

實驗設置

五種基線、三項指標，STAIR 與 DSI 使用相同基座模型

對照基線

- Mistral Instruct v0.2：原生 LLM，beam search 產生 Top-K 候選
- BM25：Elastic Search 索引，葉節點作為文件識別碼
- DPR：NV-Embed-v2 開箱即用（MTEB 榜首開源嵌入模型）
- DSI：與 STAIR 用同一基座微調，但輸入不含 ToC
- Haiku：Claude Haiku 4.5，作為額外對照

評測指標

- Recall@1（R@1）
- Recall@3（R@3）
- nDCG@3
- 全部以 BeIR 工具套件計算

微調設定

- 基座：Mistral Instruct v0.2 + LoRA（r=16, α=32）
- 最長 200 epoch，早停耐心值 20（以 dev set R@1 為準）
- 輸入長度上限：STAIR 14k tokens／DSI 512 tokens
- 輸出長度上限：64 tokens

Source: §5.1–5.2, Table 4 caption, arXiv:2609.03874v1, pp.5-8

主要結果

STAIR 平均 Recall@1 達 82.6%，較最強基線 DSI 高 7.4 個百分點

Table 4: Recall@1, Recall@3 and nDCG@3 for **SearchTome**; Haiku is Claude haiku 4.5

	Education	Finance	Law	Med	NatSci	SocSci	Avg
Mistral	14.8/17.8/16.6	16.4/19.4/18.2	13.6/15.7/14.9	13.7/17.0/15.7	13.1/15.3/14.4	10.9/13.4/12.4	13.8/16.4/15.4
BM25	58.7/75.8/68.8	55.0/76.8/67.8	62.0/77.7/71.3	59.6/78.7/70.8	58.7/78.1/70.1	62.8/78.3/72.0	59.5/77.6/70.1
Haiku	59.8/80.4/72.0	37.7/56.3/48.4	41.1/60.6/52.3	46.1/65.0/57.2	54.6/73.7/65.7	34.0/48.8/42.6	45.6/64.1/56.4
DPR	71.5/86.8/80.6	66.4/85.5/77.7	69.6/84.1/78.2	72.7/88.8/82.2	63.0/84.1/75.7	68.8/83.1/77.3	68.7/85.4/78.6
DSI	76.2/84.1/80.9	78.1/87.8/83.9	73.3/82.9/79.0	82.1/89.9/86.8	76.2/84.7/81.3	75.4/82.2/79.4	76.9/85.3/81.9
STAIR	**83.3/91.2/88.0**	**82.8/91.4/88.0**	**80.8/89.4/85.9**	**86.1/93.2/90.3**	**80.6/90.4/86.4**	**81.8/89.0/86.1**	**82.6/90.8/87.5**

82.6%
STAIR 平均 R@1（六領域）

76.9%
DSI 平均 R@1（次佳系統）

59.5%
BM25 平均 R@1（詞面比對）

13.8%
Mistral 原生 R@1（未微調）

— 唯一的輸入差異只有 ToC： STAIR 與 DSI 同基座、同訓練流程， STAIR 領先幅度可歸因於目錄結構本身。

Source: Table 4, arXiv:2609.03874v1, p.8

穩健性檢驗

六大領域皆通過顯著性檢定：差距不是資料規模的巧合

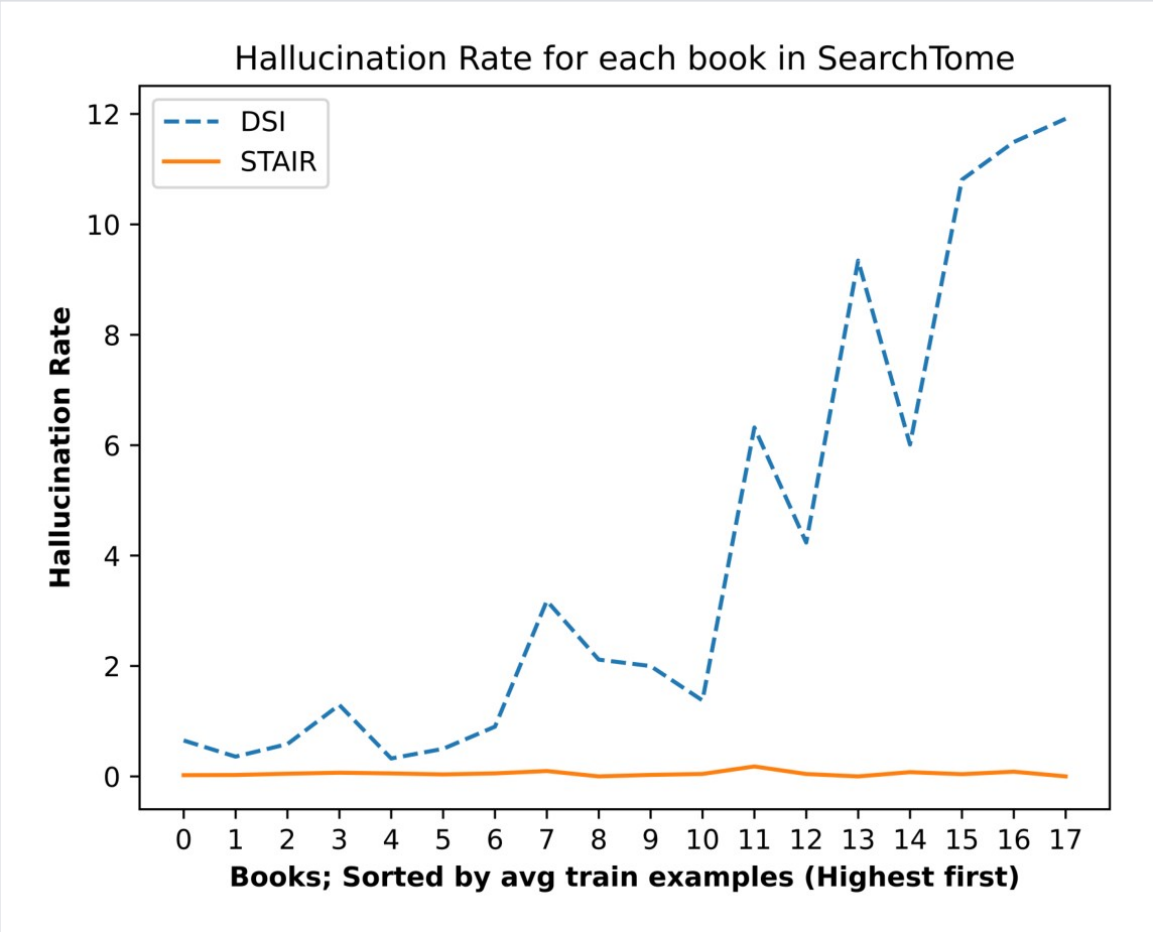
- 採用 Smucker et al. (2007) 為檢索系統量身設計的隨機化檢定（randomization test）。
- 虛無假設： DSI 與 STAIR 的輸出來自同一分布， Recall@1 差異只是抽樣變異。
- 以 p = 0.05 為門檻，分別在 6 個領域（教育 / 財務 / 法律 / 醫學 / 自然科學 / 社會科學）獨立檢定。
- 六個領域的虛無假設全數被拒絕： STAIR 對 DSI 的領先幅度在統計上顯著。

p < 0.05 ✓	p < 0.05 ✓	p < 0.05 ✓	p < 0.05 ✓	p < 0.05 ✓	p < 0.05 ✓
Education 教育	Finance 財務	Law 法律	Med 醫學	NatSci 自然科學	SocSci 社會科學

結論： Recall@1 的提升來自 STAIR 的設計本身，而非 SearchTome 的資料量或資料分布

Source: §6, arXiv:2609.03874v1, p.6

有 ToC 輸入，STAIR 的幻覺率幾乎恆為零



— 幻覺定義：模型生成了「非葉節點」的識別碼，也就是 ToC 裡不存在的章節。

— 訓練樣本越少的書，DSI 幻覺率越高，最高衝到接近 12%。

— STAIR 不論書籍訓練樣本多寡，幻覺率都貼著 0，因為推論階段用限制式生成，只能輸出合法葉節點。

— 整體而言 STAIR 的幻覺率低於 0.05%，遠低於 DSI。

Source: Figure 3, arXiv:2609.03874v1, p.8

消融研究 · 低資源

訓練樣本越少的章節，STAIR 相對 DSI 的優勢越大



— 橫軸依「每個葉節點的訓練樣本數」由少到多排序，縱軸為滑動視窗（100）計算的 Recall@1。

— 沒有 ToC 的 DSI 必須自行「發現並記住」書本結構，訓練樣本稀少的葉節點特別容易被漏掉。

— STAIR 不需要「記住」葉節點——直接讀取輸入中的 ToC，因此小樣本區間依然維持較高 Recall@1。

— 隨著訓練樣本增加，兩者差距縮小，但 STAIR 全程保持領先。

Source: Figure 4, arXiv:2609.03874v1, p.8

案例分析

同一道題，五套系統給出五種答案——只有 STAIR 命中

書籍：The Whole Child: Development in the Early Years ｜ 查詢：「當照顧者與教師貶低學齡前兒童的自主行為時，孩子會有什麼反應？」

系統	預測結果	判讀
Mistral	同時吐出 3 個候選（含正解），未學會只能選一個	缺乏任務微調
BM25	8.3.2 Moral Development	純詞面重疊，選錯章節
DPR	2.2.2 Autonomy vs. Shame/Doubt (Toddlerhood)	詞義相近但語料未微調，選錯
DSI	2.2.2 Autonomy vs. Shame/Doubt (Preschool years)	看似合理，實為幻覺出的章節標題（ToC 中不存在）
STAIR	**2.2.3 Initiative vs. Guilt (Preschool Years) ✓ 正解**	**準確命中金標準葉節點**

Source: Table 3 (Example 1) & §6.2, arXiv:2609.03874v1, p.7

適用邊界

目前只驗證於「本來就有目錄結構」的語料

- 評測語料本身都已具備清楚的全域結構（教科書目錄），尚未涵蓋沒有現成 ToC 的真實場景。
- 尚未在人工／動態建構 ToC 的標準長文件基準上驗證。
- 尚未測試企業級規模語料——例如可能多達數百萬條網址的內部文件庫。

本文已驗證規模

6 大領域・ 18 本開放教科書・ 2,880 個 ToC 葉節點
（皆為本來就帶有清楚目錄結構的語料）

→

未來待驗證規模

企業級語料・不存在現成 ToC 的文件
可能多達數百萬條網址的內部文件庫

下一步：把「建構 ToC」也交給系統自己完成，而不是假設它已經存在

Source: §8 Limitations, arXiv:2609.03874v1, p.9

結論與未來方向

把「目錄」變成檢索訊號，而不是被丟棄的雜訊

- STAIR 首次把書本／長文件的目錄（ToC）當作 model-based indexing 的檢索單元與訓練訊號。
- 在 6 大領域、 18 本書的 SearchTome 上， STAIR 全面超越 BM25 、 DPR 、 DSI 與原生 Mistral 。
- 未來方向：對未見語料動態建構類 ToC 結構；發展零樣本、可迭代檢索並對葉節點內容做推理的代理式（ agentic ）多跳檢索。

82.6%
Recall@1 ，較 DSI +7.4 個百分點

<0.05%
幻覺率（生成非法葉節點的比例）

6 / 6
領域皆通過顯著性檢定（ p<0.05 ）

Source: §7 Conclusion & §6, arXiv:2609.03874v1, pp.8-9